Propuesta del Proyecto Final:

Asistente virtual inteligente basado en generación aumentada por recuperación (RAG) con actualización automática de la información institucional de la Universidad Tecnológica de Bolívar

Mario Alberto Julio Wilches, T00077314
Ana Sofia Meza Herrera, T00077991
Alejandro Villarreal Imitola, T00077164
Juan Carlos Narvaez Castaño, T00078519

Revisado Por
Prof. Edwin Alexander Puertas Del Castillo

INTELIGENCIA ARTIFICIAL
UNIVERSIDAD TECNOLÓGICA DE BOLÍVAR
Escuela de Transformación Digital

Noviembre de 2026

1. Descripción General

"ToolIA-Bot" será un chatbot universitario diseñado para centralizar y facilitar el acceso a la información institucional de la Universidad Tecnológica de Bolívar (UTB). Permitirá que estudiantes, aspirantes, docentes y administrativos realicen preguntas en lenguaje natural sobre reglamentos, manual de convivencia, calendario académico, procesos administrativos, requisitos, servicios y demás información publicada en la página web.

El sistema utilizará generación aumentada por recuperación (Retrieval-Augmented Generation, RAG) como núcleo de inteligencia artificial. Esto permitirá recuperar información relevante de documentos institucionales y la página web oficial antes de generar una respuesta mediante un modelo de lenguaje (LLM).

Una de las características principales del asistente virtual será su capacidad de actualizar automáticamente su base de conocimiento cuando detecte modificaciones en los documentos o contenidos de las fuentes institucionales. Para ello, contará con un mecanismo de monitoreo periódico de las páginas web oficiales, descarga de documentos y detección de cambios. Cuando se identifique una actualización, el sistema procesará nuevamente el contenido afectado y actualizará su índice de búsqueda.

Además, proporcionará referencias a los documentos y secciones utilizados para construir cada respuesta, con el propósito de mejorar la transparencia, trazabilidad y confiabilidad de la información.

2. Planteamiento del Problema

Las universidades manejan gran cantidad de información relacionada con sus programas académicos, procesos de admisión, becas, alternativas de financiación, cursos, reglamentos, calendarios y demás procedimientos institucionales. Esta información suele encontrarse distribuida en diferentes secciones de sus páginas web y en documentos digitales, como archivos PDF, reglamentos y comunicados oficiales.

Esta dispersión puede dificultar que los usuarios encuentren respuestas oportunas y precisas a sus consultas rápidamente y sin confusiones, aún más cuando existen documentos extensos. Adicionalmente, los canales digitales de información no siempre ofrecen mecanismos de consulta interactivos que permitan formular preguntas utilizando lenguaje natural y obtener respuestas contextualizadas.

Ante esta situación, se propone desarrollar ToolIA-Bot un asistente virtual inteligente que permita consultar información institucional mediante preguntas realizadas en lenguaje natural y mantenga su conocimiento actualizado automáticamente. El sistema utilizará técnicas de procesamiento de lenguaje natural y modelos de lenguaje de gran tamaño (LLM), complementados con generación aumentada por recuperación (RAG), para localizar información relevante en fuentes institucionales y generar respuestas fundamentadas en su contenido.

3. Objetivos

Objetivo General

Desarrollar un chatbot universitario basado en Retrieval-Augmented Generation (RAG) que permita consultar información institucional de la Universidad Tecnológica de Bolívar mediante lenguaje natural, recuperando información de documentos y páginas web oficiales y actualizando automáticamente su base de conocimiento cuando se detecten modificaciones en las fuentes.

Objetivos Específicos

- Identificar y recopilar documentos y páginas web oficiales que contengan información relevante para la comunidad UTB.
- Desarrollar un mecanismo automático de monitoreo de fuentes institucionales que permita detectar, descargar y procesar documentos actualizados.
- Implementar un sistema RAG que procese documentos y recupere fragmentos relevantes para responder preguntas.
- Integrar un modelo de lenguaje que genere respuestas fundamentadas en la información recuperada.
- Evaluar experimentalmente el desempeño del sistema mediante su comparación con un modelo de lenguaje sin recuperación documental.
- Identificar y analizar los errores, limitaciones y riesgos relacionados con la privacidad, seguridad y confiabilidad de las respuestas.

4. Usuarios objetivo

El sistema está dirigido a toda la comunidad universitaria UTB y a las personas interesadas en acceder a información de la institución. Entre los usuarios principales se encuentran:

- Aspirantes y familias: Personas interesadas en conocer la oferta de la universidad, requisitos de admisión, procesos de inscripción y becas, alternativas de financiación.
- Estudiantes: Personas que necesitan consultar reglamentos, calendarios académicos, procedimientos administrativos, becas y servicios universitarios. En especial los de primer semestre que no conocen sobre los estatutos, reglas y normas, y en donde encontrarlos.
- Docentes y personal administrativo: Integrantes de la universidad que requieren información sobre procesos académicos, políticas, servicios, documentación, estatutos, reglas y normas institucionales.
- Otras personas de la comunidad UTB que necesiten acceder a información general sobre la universidad.

5. Alcance del Proyecto

Fuentes de Información

Se utilizarán las fuentes públicas y oficiales de la universidad, la información encontrada en la página web https://www.utb.edu.co/, especialmente los reglamentos, el calendario

académico, programas y cursos ofrecidos, información sobre admisiones y matrículas, servicios universitarios y financiamiento ofrecido.

No se procesará información personal, privada ni de acceso restringido.

Funcionalidades Principales

- Consulta mediante lenguaje natural: El usuario podrá realizar preguntas sobre la información de la UTB sin necesidad de conocer el documento exacto, artículo o parte de la página donde se encuentra la respuesta.
- Generación de respuestas: Un modelo de lenguaje utilizará la información recopilada para construir respuestas claras y contextualizadas.
- Referencias: Las respuestas incluirán el nombre del documento, página o sección correspondiente cuando sea posible y pertinente.
- Actualización automática: El sistema deberá monitorear periódicamente la fuente de información institucional y actualizar su conocimiento en el caso de encontrar modificaciones.
- Control de respuestas: Si no cuenta con información suficiente para responder, el chatbot deberá reconocerlo explícitamente en lugar de alucinar o inventar información.

6. Ruta de Proyecto

La ruta del proyecto será la D: Lenguaje natural y LLM. Esta comprende técnicas de procesamiento de lenguaje natural, embeddings, transformers y RAG. La técnica central sería RAG, combinando recuperación de información con generación de texto.

Funcionamiento de RAG

Los documentos y páginas oficiales de la UTB se convertirán en una base de conocimiento vectorial. Cuando un usuario haga una pregunta, el sistema recuperará los fragmentos más similares semánticamente, se los pasará al LLM junto con la pregunta y con instrucciones de responder únicamente con base en ese contexto, y mostrará la respuesta con sus fuentes. Si el contexto recuperado no es suficiente, el LLM deberá indicar que no cuenta con la información. Adicionalmente, un proceso independiente mantendrá esa base de conocimiento al día cuando las fuentes cambien.

El funcionamiento se dividirá en tres procesos.

Procesamiento e indexación documental

1. Obtener documentos y contenidos de las páginas oficiales.
2. Extraer el texto de los documentos.
3. Limpiar y organizar el contenido.
4. Dividir el texto en fragmentos o chunks.
5. Generar embeddings de los fragmentos.
6. Almacenar los vectores y sus metadatos en una base de datos vectorial.

Recuperación y generación de respuestas

1. Recibir la pregunta del usuario.

2. Convertir la pregunta en un embedding y consultar la base de conocimiento.
3. Recuperar la información relevante de la base de conocimientos.
4. Enviar la pregunta y el contexto recuperado al modelo de lenguaje, con instrucciones de responder solo con base en dicho contexto.
5. Generar una respuesta basada en la información recuperada.
6. Mostrar la respuesta al usuario junto con sus fuentes.

Actualización automática de la base de conocimiento

1. Revisar periódicamente (por ejemplo, cada día) las URLs y documentos configurados como fuentes.
2. Calcular una huella (hash) del contenido de cada fuente y compararla con la almacenada.
3. Si hay cambios, descargar y reprocesar únicamente el contenido afectado (pasos 2 a 6 del Proceso 1).
4. Reemplazar en la base vectorial los fragmentos antiguos por los nuevos y registrar la fecha de actualización.

7. Justificación de la Técnica

El problema planteado exige que el asistente responda con información específica, verificable y vigente de una institución concreta. Se evaluaron las siguientes alternativas:

Alternativa	Limitación frente al problema
LLM sin recuperación	Responde con conocimiento aprendido en su entrenamiento, que puede estar desactualizado y no incluir documentos internos de la UTB. Además, tiende a generar texto plausible pero incorrecto (alucinaciones) y no puede citar fuentes (Ji et al., 2023).
Ajuste fino (fine-tuning) del LLM	Es costoso y obliga a reentrenar cada vez que cambia un reglamento o calendario, lo cual contradice el requisito de actualización automática. Tampoco permite señalar de qué documento proviene cada respuesta.
Pasar todos los documentos en el prompt	Los reglamentos y documentos institucionales son extensos; incluirlos completos aumenta el costo y la latencia, y puede superar la ventana de contexto del modelo.
Buscador por palabras clave o chatbot basado en reglas	No interpreta preguntas en lenguaje natural ni redacta respuestas contextualizadas; exige que el usuario use los términos exactos del documento.
RAG	Combina búsqueda semántica con generación, permite actualizar el conocimiento reindexando documentos sin reentrenar el modelo, y habilita citar las fuentes usadas.

Lewis et al. (2020), autores de la propuesta original de RAG, plantean que combinar la memoria paramétrica del modelo con una memoria no paramétrica (un índice de documentos) mejora el desempeño en tareas intensivas en conocimiento, permite actualizar el conocimiento del sistema y ofrece trazabilidad sobre el origen de la información. Revisiones posteriores del área describen a RAG como una de las estrategias principales para reducir

alucinaciones y mantener actualizados a los LLM (Gao et al., 2023). Russell y Norvig (2021) presentan los modelos de lenguaje basados en transformers y su uso en tareas de procesamiento de lenguaje natural, que son la base de los componentes de embeddings y generación de este proyecto.

8. Evaluación Antes de Experimentar

La evaluación permitirá determinar si utilizar RAG mejora o no la calidad de las respuestas frente a un modelo de lenguaje que responde sin consultar documentos institucionales.

Línea Base

Se hará uso de un LLM sin recuperación documental. El modelo recibirá las preguntas y generará respuestas haciendo uso de su conocimiento previo, sin consultar la base documental de la universidad.

Modelo Propuesto

El mismo modelo de lenguaje de la línea base integrado con el sistema RAG. El modelo recibirá la información recuperada de los documentos institucionales para construir sus respuestas. Al usar el mismo LLM en ambos casos, cualquier diferencia en los resultados puede atribuirse a la recuperación documental.

Pruebas

Se construirá un conjunto de 50 preguntas de prueba relacionadas con la información de la página web. Cada pregunta tendrá una respuesta de referencia conocida y, cuando corresponda, una fuente identificada.

Se incluirán preguntas sobre fechas y calendarios, reglamentos, procedimientos, ofertas financieras e institucionales, entre otras que requieran localizar información en diferentes documentos. Además, aproximadamente 10 de las 50 preguntas corresponderán a asuntos cuya respuesta no se encuentra en las fuentes (por ejemplo, información que la UTB no publica), con el fin de poder medir la tasa de abstención. Las otras 40 tendrán respuesta documentada.

Métricas

- Exactitud de respuesta: Medir que tanto la respuesta coincide con la información de referencia.
- Fidelidad a las fuentes: Determinar si la respuesta está respaldada por los documentos recuperados.
- Tasa de alucinación: Identificar respuestas que presentar información no respaldada.
- Tasa de abstención: Medir si el sistema evita responder cuando no tiene información suficiente.
- Latencia: Medir el tiempo necesario para generar una respuesta
- Recall@5: Medir si los fragmentos relevantes aparecen entre los cinco primeros resultados recuperados. Si la respuesta correcta no entra en ese "Top 5" inicial, el chatbot no podrá responderle bien al usuario.

Umbrales de Éxito

- Exactitud de respuesta: ≥ 75 % en el sistema RAG, y al menos 15 puntos porcentuales por encima de la línea base.
- Fidelidad a las fuentes: ≥ 80 % de las respuestas respaldadas por los fragmentos recuperados.
- Tasa de alucinación: ≤ 15 %.
- Tasa de abstención: ≥ 70 % de las preguntas sin respuesta en las fuentes.
- Latencia: ≤ 10 s en promedio.
- Recall@5: ≥ 80 %.

El proyecto se considerará exitoso si el sistema RAG cumple al menos cinco de los seis umbrales y supera a la línea base en exactitud y tasa de alucinación.

Análisis de Errores

Se analizarán al menos 10 casos en los que el sistema presente resultados incorrectos o insatisfactorios. Los errores podrán clasificarse en:

- Fallos de recuperación o extracción de documentos.
- Información incompleta.
- Interpretación incorrecta de documentos.
- Respuestas no respaldadas.
- Información desactualizada.

La manera de cómo asegurar que se pueda realizar este análisis depende de:

- Se analizarán los errores de ambos sistemas (línea base y RAG), no solo los del modelo propuesto.
- Si con las 50 preguntas el RAG produce menos de 10 errores, se ampliará el conjunto con preguntas adicionales más difíciles (ya sean preguntas que requieran de múltiples documentos para contestarse, preguntas ambiguas o con redacción coloquial) hasta completar los casos requeridos.
- La categoría "información desactualizada" puede no aparecer de forma natural durante las pruebas. Para evaluarla se simulará un cambio en una fuente (por ejemplo, modificar la fecha de un calendario en una copia de prueba) y se verificará si el sistema detecta el cambio y responde con la información nueva.

9. Diseño PEAS

El agente se describe mediante el marco PEAS (Medida de desempeño, Entorno, Actuadores y Sensores) de Russell y Norvig (2021).

Medida de Desempeño

Exactitud de respuesta, fidelidad a las fuentes, tasa de alucinación, tasa de abstención, latencia y Recall@5 (ver umbrales en la sección 8). También, que la base de conocimiento refleje los cambios de las fuentes tras cada ciclo de actualización.

Entorno

- Página web oficial de la UTB y sus documentos digitales (PDF, reglamentos, calendarios, comunicados)
- La base de datos vectorial
- Los usuarios (aspirantes, estudiantes, docentes y administrativos) que consultan mediante una interfaz de chat.

Actuadores

- Respuesta en lenguaje natural con referencias a las fuentes
- Mensaje de abstención cuando no hay información suficiente
- Descarga y reprocesamiento de documentos modificados
- Actualización del índice vectorial.

Sensores

- Pregunta del usuario en texto.
- Contenido HTML y archivos descargados de las páginas oficiales.
- Huellas (*hash*) o fechas de modificación de las fuentes para detectar cambios.
- Fragmentos devueltos por el recuperador.

Bibliografía

Belcic, I. (2025, October 3). ¿Qué es RAG (generación aumentada por recuperación)? IBM. https://www.ibm.com/mx-es/think/topics/retrieval-augmented-generation

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2023). Retrieval-augmented generation for large language models: A survey. arXiv. https://arxiv.org/abs/2312.10997

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), 1–38. https://doi.org/10.1145/3571730

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, 33, 9459–9474.

Russell, S., & Norvig, P. (2021). Artificial intelligence: A modern approach, global edition (4th ed.). Pearson Education.